Palm LCI เว็บต้นแบบของกลุ่ม S02-G07

คู่มือสำหรับทีม เว็บนี้ทำอะไร แต่ละส่วนใช้อะไร และตอบคำถามกรรมการยังไง อัปเดต 13 พ.ย. 2569

เว็บนี้คืออะไร

เว็บแอปหน้าเดียวที่นำข้อมูลจากฐานข้อมูล 5NF ของทีมมาแสดง และให้ถามคำถามแบบ RAG ได้ รันบนเครื่องผู้นำเสนอที่ `http://127.0.0.1:8080` ไม่ได้ขึ้นเว็บจริง ไม่ต้องมีฐานข้อมูลออนไลน์

โค้ดอยู่ในโฟลเดอร์ S02-G07_ui ของ repo `github.com/andrewtsn/S02-G07-ch6` วิธีติดตั้งและเปิดเว็บดูในไฟล์ S02-G07_วิธีรันเว็บ.pdf แต่ละคนใช้คีย์ Gemini ของตัวเอง

เทคโนโลยีที่ใช้

ส่วน	ใช้อะไร	อยู่ที่ไหน
หน้าเว็บ	HTML CSS JavaScript ล้วน ไม่ใช้ framework กราฟทุกตัวเขียนเป็น SVG เอง	static/index.html
เซิร์ฟเวอร์	Python และ Flask ส่งข้อมูลให้หน้าเว็บเป็น JSON	app.py
อ่านและคำนวณข้อมูล	pandas และ NumPy อ่าน CSV ตอนเปิดเว็บแล้วเก็บไว้ในหน่วยความจำ	app.py และโฟลเดอร์ data
แปลงข้อความเป็นเวกเตอร์	sentence-transformers โมเดล paraphrase-multilingual-MiniLM-L12-v2 ขนาด 384 มิติ ตัวเดียวกับ Colab	app.py
ค้นหาเชิงความหมาย	ความคล้ายโคไซน์ด้วย NumPy ดึง 5 อันดับ เกณฑ์ 0.40	app.py
AI เรียบเรียงคำตอบ	Google Gemini ผ่านไลบรารี google-genai รุ่น gemini-3.5-flash-lite	app.py
ฟอนต์และไอคอน	Anuphan กับ IBM Plex Sans Thai และไอคอน Lucide เก็บไว้ในเครื่อง ไม่ต้องต่อเน็ต	static/fonts
ทดสอบ	S02-G07_selftest.py ถามคำถามจริงด้วยโมเดลจริง S02-G07_modelcheck.py วัดความเร็วรุ่น Gemini	โฟลเดอร์หลัก

5 หน้าบนเว็บ

หน้า	มีอะไร	ข้อมูลจาก
ภาพรวม	ห่วงโซ่ ปลูก ขนส่ง สกัด ก๊าซเรือนกระจกแต่ละขั้น สลับหน่วยได้ และตัวเลขขอบเขตข้อมูล 7,620 แถว 29 ตาราง 9 กระบวนการ 104 รายการผ่านการตรวจทั้งหมด 6 แหล่ง	PROCESS v_ghg_per_t_cpo table_counts v_lci_exchange SOURCE
ถามจากหลักฐาน	พิมพ์คำถาม ระบบค้น 5 หลักฐานจาก 41 ทริปเปิล ตอบทันที และกดให้ Gemini เรียบเรียงได้	triples.csv triples_provenance.csv
สถิติการผลิต	ผลผลิตทั้งประเทศ ปี 2525 ถึง 2567 จังหวัดผู้ผลิตสูงสุด 10 อันดับแบบกดเล่นทีละปี ผลผลิตรายภาค และน้ำที่ใช้รายภาค	PRODUCTION_STAT 6,960 แถว STAT_AREA STAT_ITEM SRC01_WATER

บัญชีรายการ	Input และ Output ของแต่ละกระบวนการ กรองได้ ดาวน์โหลด CSV ได้ แต่ละแถวบอกแหล่งข้อมูลและผลการตรวจ	v_lci_exchange v_exchange_status PROCESS
แหล่งข้อมูล	แหล่งอ้างอิง 6 แหล่ง วารสาร ปี และกระบวนการที่ใช้แหล่งนั้น พร้อมลิงก์เอกสาร	SOURCE PROCESS_SOURCE

CSV ทุกไฟล์ในโฟลเดอร์ data มาจากฐานข้อมูล 5NF ชุดเดียวกับบน GitHub ไฟล์ที่ขึ้นต้นด้วย v_ คือผลของ view ใน S02-G07_DDL.sql ส่วน triples.csv คือ 41 ทริปเปิลชุดเดียวกับ Colab W14

หน้าถามจากหลักฐานทำงานยังไง

1 MiniLM แปลงคำถามเป็นเวกเตอร์ **2** เทียบกับ 41 ทริปเปิล เอา 5 อันดับ **3** ตรวจเกณฑ์ 0.40 และตรวจคำแปลก **4** ตอบจากหลักฐานทันที **5** กดถาม Gemini ได้

ขั้น 3 ด่านตรวจ 2 ด่าน

- **คะแนนต่ำกว่า 0.40** ตอบว่าไม่พบข้อมูลที่เกี่ยวข้อง เช่น ถามเรื่องรถไฟฟ้า
- **มีคำที่ไม่อยู่ใน 41 ทริปเปิลเลย** เช่น โนบิตะ ระบบไม่ตอบเอง แต่ส่งให้ Gemini อ่านหลักฐานแล้วตัดสินอัตโนมัติ

ขั้น 4 คำตอบจากหลักฐาน

เอาประโยคของทริปเปิลที่ตรงที่สุดมาเป็นคำตอบ ไม่มี AI แต่งประโยค เหมือนโหมด template ในช่อง 5 ของ Colab อาจารย์มีกฎเพิ่ม 2 ข้อ

- คำถามที่ถามจำนวน ใช้แถวอันดับสูงสุดที่มีตัวเลข
- แถวที่เป็นเรื่องเดียวกันรวมมาตอบด้วย เช่น ปุ๋ย N ตอบทั้ง T17 และ T22

ขั้น 5 Gemini เรียบเรียงคำตอบ

ส่งคำถามกับหลักฐาน 5 อันดับให้ Gemini พร้อมคำสั่งให้ตอบจากหลักฐานเท่านั้นและอ้างรหัส T รอสูงสุด 12 วินาที ถ้าการเชื่อมต่อหลุดจะลองใหม่ทันทีหนึ่งครั้ง ถ้ายังไม่ได้ คำตอบจากหลักฐานยังอยู่บนจอ

สองแบบต่างกันยังไง

	คำตอบจากหลักฐาน	Gemini เรียบเรียง
ข้อความมาจาก	ประโยคในทริปเปิลตรงตัว	Gemini อ่านหลักฐาน 5 อันดับแล้วเขียนใหม่
ความเร็ว	ไม่ถึงวินาที	ราว 1.5 ถึง 3.6 วินาที
ต้องใช้เน็ต	ไม่ต้อง	ต้อง
ข้อดี	แต่งเรื่องเองไม่ได้ ผลเหมือนเดิมทุกครั้ง	อ่านลื่น และตัดสินได้ว่าหลักฐานตรงคำถามจริงไหม
จุดอ่อน	ถ้า MiniLM หยิบแถวผิด คำตอบผิดตาม	ช้ากว่า และขึ้นกับว่า Google ว่างไหม

คำที่ควรรู้

คำ	ความหมาย
RAG	ให้ระบบค้นหลักฐานก่อน แล้วตอบจากหลักฐานนั้นเท่านั้น แทนการให้ AI ตอบจากความจำ

ทริปเปิล	ข้อเท็จจริงหนึ่งข้อในรูป ประธาน ความสัมพันธ์ ค่า เช่น T30 การปลูกภาคใต้ ต้องใช้น้ำชลประทาน 183 m3 ต่อผลปาล์ม 1 ตัน
เวกเตอร์ฝังตัว	ตัวเลข 384 ตัวที่ MiniLM สร้างจากประโยค ประโยคที่ความหมายใกล้กันจะได้ตัวเลขใกล้กัน
ค้นหาเชิงความหมาย	ค้นจากความหมาย ไม่ต้องพิมพ์คำตรงกับข้อมูล เช่น ถามว่าภาคใต้ใช้น้ำเท่าไรก็เจอ T30
ความคล้ายโคไซน์	คะแนน 0 ถึง 1 บอกว่าคำถามกับหลักฐานคล้ายกันแค่ไหน ยิ่งใกล้ 1 ยิ่งคล้าย
เกณฑ์ 0.40	ถ้าหลักฐานที่ดีที่สุดได้คะแนนต่ำกว่านี้ ระบบตอบว่าไม่พบข้อมูลที่เกี่ยวข้อง ค่าเดียวกับ Colab
Grounded prompt	คำสั่งที่ส่งให้ Gemini บังคับให้ตอบจากหลักฐานที่แนบไปเท่านั้นและอ้างรหัส T
5NF	รูปแบบฐานข้อมูลของทีม แยกตารางจนไม่มีข้อมูลซ้ำ CSV ทุกไฟล์ในเว็บมาจากฐานข้อมูลนี้

คำถามที่กรรมการอาจถาม

คำถาม	ตอบว่า
ทำไมถามได้แค่ 41 ทริปเปิล	โจทย์ M4 ให้ทำ 20 ถึง 50 แถว เราคัดมาให้ครบทุกประเภทข้อมูล ข้อมูลอื่นดูได้ในหน้าสถิติและบัญชีรายการ
ถามเรื่องที่มีในฐานข้อมูล เช่น กระบี่ปี 2558 ทำไมไม่เจอ	ข้อมูลรายจังหวัดอยู่ใน PRODUCTION_STAT ไม่ได้อยู่ใน 41 ทริปเปิล ระบบจึงตอบว่าไม่พบแทนการเดา ซึ่งเป็นสิ่งที่ RAG ควรทำ
ถามมั่ว เช่น โนบิตะ ระบบจะตอบไหม	ไม่ตอบเอง ระบบเจอคำที่ไม่อยู่ในคลังความรู้ จึงส่งให้ Gemini ตัดสิน และ Gemini ตอบว่าไม่พบข้อมูล
ทำไมเว็บไม่ใช้ pgvector เหมือน Colab	ข้อมูลมีแค่ 41 แถว คำนวณในหน่วยความจำได้ทันที ใช้โมเดลและความคล้ายโคไซน์แบบเดียวกับ Colab ส่วน pgvector อยู่ในงาน Colab หัวข้อ 6.6
ทำไมใช้ Gemini คนละรุ่นกับ Colab	วัดวันที่ 13 พ.ย. รุ่น 3.8-flash ล้ม 4 จาก 4 ข้อเพราะ Google มีคนใช้มาก รุ่น 3.5-flash-lite ตอบสำเร็จ 4 จาก 4 ข้อ
ถ้าเน็ตหลุดหรือ Gemini ล่ม	คำตอบจากหลักฐานยังขึ้นปกติ เพราะไม่ต้องใช้เน็ต ปุ่ม Gemini ขึ้นกล่องแจ้งและให้กดลองใหม่
ข้อจำกัดของ MiniLM	แยกแถวที่ต่างกันแค่ปีได้ไม่ดี เช่น T38 ปี 2567 กับ T41 ปี 2566 จึงแสดงคะแนนและหลักฐานทุกอันดับให้ตรวจได้

ผลทดสอบบนเครื่องทีม 13 พ.ย.

- **คำตอบจากหลักฐาน** ถูก 5 จาก 5 ข้อที่มีคำตอบในคลัง ข้อรถไฟฟ้าตอบว่าไม่พบถูกต้อง ค้นหาเฉลี่ย 12 มิลลิวินาที
- **Gemini รุ่น 3.5-flash-lite** สำเร็จ 4 จาก 4 ข้อ ใช้ 1.5 ถึง 3.6 วินาที ตัวเลขตรงกับ triples.csv ทุกข้อ

วันนำเสนอ

1. ก่อนขึ้น 30 นาที รัน `python3 S02-G07_modelcheck.py` ถ้า 3.5-flash-lite ล้ม ให้ `export GEMINI_MODEL="gemini-flash-lite-latest"` ก่อนรันเว็บ
2. เปิดเว็บด้วย `python app.py` มุมขวาบนต้องขึ้น โมเดลค้นหาพร้อม และชื่อรุ่น Gemini
3. บนเวทีใช้ปุ่มคำถามตัวอย่าง ให้เห็นคำตอบจากหลักฐานก่อน แล้วกดถาม Gemini
4. เตรียมวิดีโอสำรองตอนที่ Gemini ตอบสำเร็จไว้ เผื่อเน็ตในห้องมีปัญหา

คีย์ Gemini ใส่ใน Terminal ด้วย export เท่านั้น ห้ามเขียนลงไฟล์ ห้ามส่งในแชต และห้ามให้ติดในภาพหน้าจอ